



机器学习综合报告

陈继强、赵文嵩、牛晋宇、王丽娜



基于机器学习的性格分析预测，拍照点名器实现

陈继强、赵文嵩、牛晋宇、王丽娜

2019 年 1 月 7 日

摘要

经过对身边的同学，朋友的进一步调查，我发现他们对专业认知几乎为零，大部分人怀着从众心理去选取专业，他们不能根据自身的特点选取真正适合自己的专业，因此我们想通过机器学习的理论知识通过搭建深度神经网络对学生的性格进行预测，从而推荐出合适的专业。同时为了解决老师上课点名耗时的问题，我们小组通过 HOG 和 SVM 实现了拍照点名。

近年来，研究者在人格描述模式上形成了比较一致的共识，提出了人格的大五模式，Goldberg 称之为人格心理学中的一场革命，研究者通过词汇学的方法，发现大约有五种特质可以涵盖人格描述的所有方面。大五人格(OCEAN)，也被称之为人格的海洋。

功能一中，通过小组共同的努力，我们在 Google 网站上发现了大五人格的数据集，该数据集统计了两万条数据，通过对数据的分析，可以评测出每个人的性格特点主要集中五大人格的某一方面，从而可以确定每个人的性格类型。根据美国心理学家的职业兴趣理论，该理论认为人的人格类型、兴趣与职业密切相关，因此我们可以根据所得的人物性格类型推荐最适的专业。

确保性格预测的准确性，我们分别采用了深度神经网络和朴素贝叶斯分类两种方法进行预测，将两种结果进行分析对比，选出最好的模型。在进行对数据的训练时，首先我们需对数据集进行预处理，数据集中缺少标签，因此我们通过 k-means 聚类的方法对数据进行聚类分析，大五人格有 5 种人格类型，我们将数据最终聚成了 5 类，根据聚类的结果，分析出每一类所代表的人格类型，最终成功为每个数据打标签，之后便采用两种方法进行训练。

功能二中，我们使用 dlib 提供的正面人脸检测工具，首先检测出需要分析的图片中的人脸位置，并返回相关信息。其次根据正面人脸检测工具的返回值，将人脸进行 68 个特征点的特征点标定。然后将 68 个特征点进行升维操作，变为 128 维特征向量，每个特征向量对应一个人脸。最终将要处理的图片与数据库（储存学生名单已经人脸信息）中的人脸的特征向量进行比对（采用欧氏距离 >0.6 的认为是不同人）找出出勤人员。

关键字： HOG SVM 大五人格 神经网络 k-means 聚类

1 介绍

1.1 背景

1.1.1 功能一的研究背景

经过对身边的同学，朋友的进一步调查，我发现他们对专业认知几乎为零，大部分人怀着从众心理去选取专业，他们不能根据自身的特点选取真正适合自己的专业，导致其中很多人想放弃此专业，浪费了大学宝贵时间。以计算机专业为例，很多同学学习了两年专业课后，发现自己对于根本不适合本专业的学习，逐渐的对专业失去了兴趣，开始放纵自己。因此我们小组想通过分析每个人的性格，通过心理学论文比对性格分析的结果，为学生们推荐出最合适他们的专业。

1.1.2 功能二的研究背景

大学课堂人数总是很多，老师点名会浪费很多宝贵的时间，因此老师点名的次数不会很多，于是很多学生不能受到有效的监督，选择了逃课。为此，我们小组利用机器学习的理论知识实现拍照点名，不仅节省了老师上课点名的时间，而且也能挽救一部分学生，减少他们逃课的次数。

1.2 我们的工作

- 陈继强：整合思路，研究有关性格分析心理学论文、性格所对应的合适专业论文，报告的书写与排版。
- 赵文嵩：拍照点名器的实现，部分报告的书写。
- 牛晋宇：性格预测模型中神经网络的搭建，通过聚类分析对数据进行预处理。
- 王丽娜：数据集的寻找，参与数据预处理，部分代码的编写。

2 功能重述

随着移动互联网的高速发展，人工智能热潮的兴起，我们编写了 app，app 的两大功能利用机器学习的知识进行实现，功能如下：

- a) 学生通过大五人格测试题的作答得出各部分的分值，将所得的分值送入到训练成功的性格预测模型中，模型反馈学生的性格类型，从而根据性格特点与

- 专业的关系为学生们推荐出合适的专业。
- b) 老师可以现场进行拍照，将照片送入到模型，模型反馈出未出勤的学生照片及名字，可以高效的进行点名。

3 符号表

符号	含义
β_j	输出层第 j 个神经元接受到的输入
w_{hj}	隐层第 i 个神经元与第 h 个神经元的连接权
θ_j	输出层第 j 个神经元的阈值
b_h	隐层第 h 个神经元的输出
G	梯度
H	当前位置的像素值

4 功能详解

4.1 功能一详解

4.1.1 量表的选择

本小组采用大五人格测试来对学生的性格进行分析和量化。大五人格量表，即 NEO 人格量表，是建立在大五人格的理论基础之上，由美国心理学家科斯塔和麦克雷编制而成，随着统计技术的进步和计算机在数据处理的应用，研究者们在对人格进行因素分析时，有了惊人的并且一致的发现。一些不同的研究群体从许多不同的人格资料中不断地发现关于五个人格维度的证据。它们就是：外倾型、宜人型、责任型、现实型、开放型。

开放型：抽象能力强，求知欲强，肯动脑筋，善思考，不愿动手;喜欢独立和富有创造性的工作;知识渊博，有学识才能，不善于领导他人

责任型：显示胜任、公正、条理、尽职、成就、自律、谨慎、克制等特点。

外倾性：表现出热情、社交、果断、活跃、冒险、乐观等特质

宜人性：具有信任、利他、直率、依从、谦虚、移情等特质。

现实型：愿意使用工具从事操作性强的工作;动手能力强，做事手脚灵活，动作协调;不善言辞，不善交际。

4.1.2 测试题目的设计

在下表中，对于每个陈述 1-50，在 1-5 上标记你有多少，其中 1=不同意，2=略有不同意，3 =中立，4 =略微同意，5 =同意。

部分测试题如下：

Rating	I....
	1. Am the life of the party.
	2. Feel little concern for others.
	3. Am always prepared.
	4. Get stressed out easily.
	5. Have a rich vocabulary.
	6. Don't talk a lot.
	7. Am interested in people.
	8. Leave my belongings around.
	9. Am relaxed most of the time.
	10. Have difficulty understanding abstract ideas.


评分规则如下：

$$E = 20 + (1) \text{ ______ } - (6) \text{ ______ } + (11) \text{ ______ } - (16) \text{ ______ } + (21) \text{ ______ } - (26) \text{ ______ } + (31) \text{ ______ } - (36) \text{ ______ } + (41) \text{ ______ } - (46) \text{ ______ } = \text{ ______ }$$
$$A = 14 - (2) \text{ ______ } + (7) \text{ ______ } - (12) \text{ ______ } + (17) \text{ ______ } - (22) \text{ ______ } + (27) \text{ ______ } - (32) \text{ ______ } + (37) \text{ ______ } + (42) \text{ ______ } + (47) \text{ ______ } = \text{ ______ }$$
$$C = 14 + (3) \text{ ______ } - (8) \text{ ______ } + (13) \text{ ______ } - (18) \text{ ______ } + (23) \text{ ______ } - (28) \text{ ______ } + (33) \text{ ______ } - (38) \text{ ______ } + (43) \text{ ______ } + (48) \text{ ______ } = \text{ ______ }$$
$$N = 38 - (4) \text{ ______ } + (9) \text{ ______ } - (14) \text{ ______ } + (19) \text{ ______ } - (24) \text{ ______ } - (29) \text{ ______ } - (34) \text{ ______ } - (39) \text{ ______ } - (44) \text{ ______ } - (49) \text{ ______ } = \text{ ______ }$$
$$O = 8 + (5) \text{ ______ } - (10) \text{ ______ } + (15) \text{ ______ } - (20) \text{ ______ } + (25) \text{ ______ } - (30) \text{ ______ } + (35) \text{ ______ } + (40) \text{ ______ } + (45) \text{ ______ } + (50) \text{ ______ } = \text{ ______ }$$

4.1.3 数据集处理分析


数据集描述：

通过互动在线人格测试收集了这些数据。数据集中介绍了测试者的年龄，性别，国籍，并且记录了他们的每小题的得分情况，数据集中的数据整体服从正太分布，如图所示：




数据预处理：

- 1) 根据论文所给的题目测试结果计算公式可得 E、A、C、N、O 的各部分得分情况。因此我们对每一条数据分别进行了计算。
- 2) 数据集中没有标签，因此我们通过对数据进行聚类，将数据相似的归为一类，并打上相应的标签，因为大五人格对应的是 5 种人格特征，所以我们将数据聚为 5 类。根据不同的数据个数呈现的聚类结果如图所示：



1000 个数据聚类结果




全部数据聚类结果


4.1.4 模型建立

4.1.4.1 模型一：神经网络模型

神经网络中最基本的成分是神经元模型，在这个模型中，神经元接受到来自 n 个其他神经元传递过来的输入信号，这些输入信号通过带权重的连接进行传递，神经元接受到的总输入值将将与神经元的阈值进行比较，然后通过激活函数处理以产生神经元的输出，常用的激活函数有 **sigmoid**, **ReLU** 等函数，本次我们采用的是 **ReLU** 函数作为激活函数



MP 神经元模型



ReLU 激活函数

多层网络的学习能力比单层感知机强得多，欲训练神经网络，需要强大的学习算法，误差逆传播算为迄今最成功的神经网络学习算法。

对训练 (x_k, y_k) ,假定神经网络输出为 $\hat{y}_j^k = (\hat{y}_1^k, \hat{y}_2^k, \dots, \hat{y}_l^k)$ 即

$$\hat{y}_j^k = f(\beta_j - \theta_j) \quad (1-1)$$

其中

$$\beta_j = \sum_{h=1}^q w_{hj} b_h \quad (1-2)$$

则神经网络在 (x_k, y_k) 的均方误差为：

$$E_K = \frac{1}{2} \sum_{j=1}^l (\hat{y}_j^k - y_j^k)^2 \quad (1-3)$$

BP 是一个迭代的学习算法，在迭代的每一轮中采用广义的感知机学习规则对参数进行更新估计，任意参数 v 的更新估计式为：

$$v \leftarrow v + \Delta v \quad (1-4)$$

BP 算法基于梯度下降策略，以目标的负梯度方向对参数进行调整对式 1-3 的误差 E_K ，给定学习率 η ，有

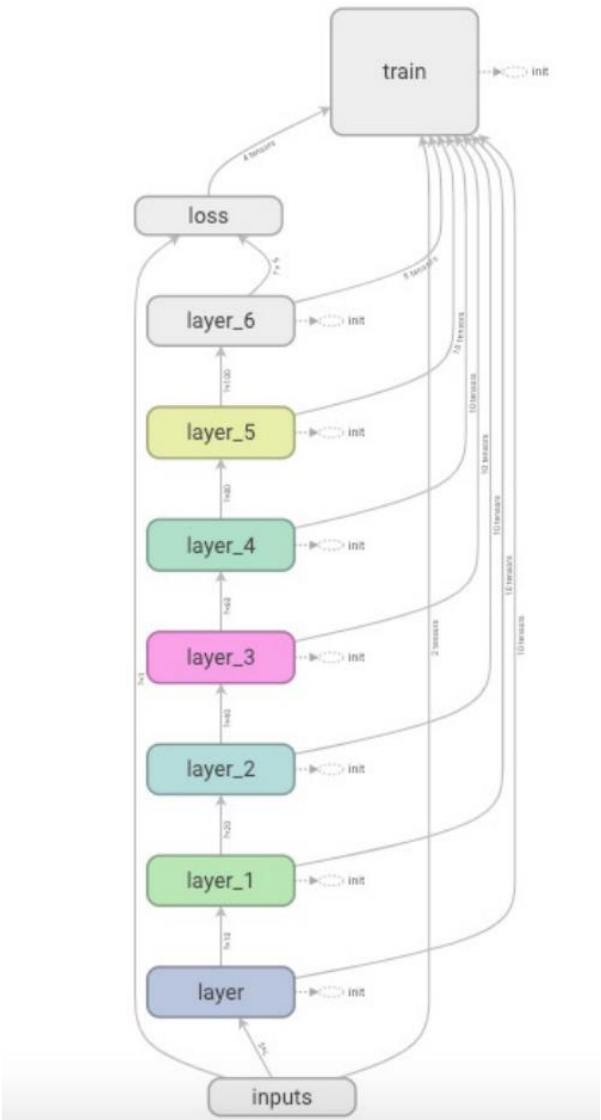
$$\Delta w_{hj} = -\eta \frac{\partial E_K}{\partial w_{hj}} \quad (1-5)$$

学习率 $\eta \in (0,1)$ 控制着算法每一轮迭代中的更新步长，若太大则容易振荡，太小则收敛速度又会过慢。

BP 神经网络经常会遭遇过拟合，其训练误差持续降低，但测试误差却可能上升，有两种策略常用来缓解 BP 网络的过拟合。第一种策略是“早停”：将数据分成训练集和验证集，训练集用来估计误差，若训练集误差降低但验证集误差升高，则停止训练，同时返回具有最小验证集误差的连接权和阈值。第二种策略是“正则化”，其基本思想是在误差目标函数中增加一个用于描述网络复杂度的部分，式 1-3 可改变为

$$E = \lambda \frac{1}{m} \sum_{k=1}^m E_K + (1 - \lambda) \sum_i w_i^2 \tag{1-6}$$


我们的神经网络架构如下图所示：




模型一结果分析：

1. 数据属性可视化：

主成分分析(PCA)是一种常用的降维方法,最大化的保留高维度属性的信息并可将高维空间的数据进行降维,我们将 5 维属性降到了三维,为了清晰的看到数据,我们分别只选了 100, 1000 个数据进行主成分分析,降维效果如图所示。




1000 个数据降维图




100 个数据降维图

2 模型损失函数图：

我们分别采用了 12000 个数据作为训练集,8000 个数据作为测试集和 16000 个数据作为训练集,4000 个数据作为测试集,不同的训练集个数据数对应的损失函数如下图所示：



12000 个数据



16000 个数据

3 不同层数的神经网络对应的准确率对比：

网络层数	准确率
4 层	92%
6 层	96%
8 层	95%

4.1.4.2 模型二：朴素贝叶斯模型

朴素贝叶斯方法是一系列有监督学习的方法，这些方法基于对贝叶斯理论的应用，即简单(naive)的假设 每对特征之间都相互独立。给定类变量 y (这里一个样本仅属于一类) 和一个相互独立的特征向量 \mathbf{x}_1 到 \mathbf{x}_n ，贝叶斯定理可得到如下关系：

$$P(y|\mathbf{x}_1, \mathbf{x}_2, \dots \mathbf{x}_n) = \frac{P(y)P(\mathbf{x}_1, \mathbf{x}_2, \dots \mathbf{x}_n|y)}{P(\mathbf{x}_1, \mathbf{x}_2, \dots \mathbf{x}_n)} \quad (1-7)$$

使用简单(naive)的假设-每对特征之间都相互独立：

$$P(\mathbf{x}_i|y, \mathbf{x}_1, \mathbf{x}_2, \dots \mathbf{x}_n) = P(\mathbf{x}_i|y) \quad (1-8)$$

对于所有 i ，这个关系式可以化简为：

$$P(y|\mathbf{x}_1, \mathbf{x}_2, \dots \mathbf{x}_n) = \frac{P(y) \prod_{i=1}^n P(\mathbf{x}_i|y)}{P(\mathbf{x}_1, \mathbf{x}_2, \dots \mathbf{x}_n)} \quad (1-9)$$

因为 $P(\mathbf{x}_1, \mathbf{x}_2, \dots \mathbf{x}_n)$ 是输入时给定的常数(特征不可动态改变)，我们可使用如下分类规则：

$$P(y|\mathbf{x}_1, \mathbf{x}_2, \dots \mathbf{x}_n) \propto P(y) \prod_{i=1}^n P(\mathbf{x}_i|y) \quad (1-10)$$

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(\mathbf{x}_i|y) \quad (1-11)$$

我们可使用最大后验概率 (MAP) 估计来估计变量 $P(y)$ 和 $P(\mathbf{x}_i|y)$ ；前者是 y 在训练集中的相对频率。各种各样的朴素贝叶斯分类器的不同之处在于，他们对 $P(\mathbf{x}_i|y)$ 的分布的认识和假设不同。

尽管它们看起来有一个过于简单的假设，朴素贝叶斯分类器仍然 在真实世界的许多情景下工作良好，在文本分类和垃圾邮件筛选领域尤其流行。它们要求少量的数据来估计必要的参数。

本次我们分别采用了三种朴素贝叶斯模型对数据进行分类预测

A) 贝叶斯模型 高斯模型

高斯模型假设这些一个特征的所有属于某个类别的观测值符合高斯分布：

$$P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i-\mu_y)^2}{2\sigma_y^2}\right) \quad (1-12)$$

B) 贝叶斯模型 伯努利模型

实现了对于服从多元伯努利分布的数据的朴素贝叶斯训练和分类算法；也就是说，对于大量特征，每一个特征都是一个 0-1 变量 (Bernoulli, boolean)。因此，这个类要求样本集合以 0-1 特征向量的方式展现。

朴素贝叶斯的伯努利模型是基于以下公式：

$$P(x_i|y) = P(i|y)x_i + (1 - P(i|y))(1 - x_i) \quad (1-13)$$

C) 贝叶斯模型 多项式模型

实现了数据服从多项式分布时的贝叶斯算法，这个分布被参数化成向量：

$$\theta_{y1}, \theta_{y2}, \dots, \theta_{yn}$$

对于每一个类别 y ，参数 n 表示特征数量 θ_{yi} 表示有 $P(x_i|y)$ 的概率对于特征 i 在一个样本中的被类 y 所拥有。

参数 θ_y 被平滑的极大似然估计法所估计，也就是说，相关频率计算：

$$\widehat{\theta}_{yi} = \frac{N_{yi} + \alpha}{N_y + \alpha n} \quad (1-14)$$

这里 $N_{yi} = \sum x_i$ 是特征 i 在训练集 T 中，在一个属于 y 类的样本中出现的次数，

而 N_y 是在类 y 中所有的特征的数量和。

模型二结果分析：

核函数	测试集准确率
高斯模型	93%
多项式模型	63%
伯努利模型	20%

4.2 功能二详解

Dlib 自带的人脸检测工具使用了 HOG+SVM 对图片进行分析，虽然准确度不如卷积神经网络但速度快很多；考虑到上课点名的准确率要求并不是很高，因为如果漏点名，老师课后确认即可。

Dlib 使用检测窗口对大图像进行扫描，所以需要分析检测窗口的内部是否有人脸，因此我们使用了 HOG 和 SVM 相结合模型实现检测分类。

4.2.1 HOG 模型建立

HOG 是 Histogram of Oriented Gradient 的缩写也就是方向梯度直方图，HOG 特征是一种在计算机视觉和图像处理中用来进行物体检测的特征描述子，也就是说可以对目标图片进行特征提取。

接下来对 HOG 特征提取的优点进行说明，由于 HOG 特征提取是在图片的局部进行操作所以它具有几何不变性所以针对于人脸这种不是固定形态的物体具有很好的效果；以及光学不变性，对于光线改变的抗干扰性强。同时，不具备旋转和尺寸不变性，减少了一定的计算量，并且可以通过提供图片大小以及方向不同的训练集来解决这一问题。

HOG 对检测窗口进行特征提取的步骤：

- 1) 灰度化
将 RGB 图进行灰度化，把图片看作是三维图片，减少了后续操作的计算量提高处理速度。
- 2) 计算每个像素点的梯度
分别计算每个像素点的水平方向梯度，以及垂直方向梯度。公式如下：

$$G_x(x, y) = H(x + 1, y) - H(x - 1, y) \quad (2-1)$$

$$G_y(x, y) = H(x, y + 1) - H(x, y - 1) \quad (2-2)$$

其中 G 为梯度 H 为当前位置的像素值。梯度幅值：


$$G(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2} \quad (2-3)$$

梯度方向：

$$\alpha(x, y) = \tan^{-1}\left(\frac{G_y(x, y)}{G_x(x, y)}\right) \quad (2-4)$$

3) 绘制 CELL 的梯度方向直方图

将图片分为若干个固定大小的 CELL，比如 CELL 的大小为 6x6，所以一个 CELL 中有 36 个像素点，同时指定一个 CELL 的直方图有 9 个 bin，也就是说将一个平面直角坐标系，按方向分为 9 份，将 36 个像素点的梯度幅值按梯度方向划分到不同的份中。最后对其进行投影，求出该 CELL 的梯度方向直方图。简而言之，就是对一个 CELL 中的所有像素点的梯度信息进行统计。这个直方图可以看做该 CELL 的特征。



4) BLOCK

将若干个 Cell 组成 BLOCK。首先指定 BLOCK 的大小，在人像方面较好的选择为 2x2。将每个 CELL 的特征向量组合起来，成为该 BLOCK 的特征向量，并进行归一化处理。

5) 求出该图像的特征向量

仅需将所有的 BLOCK 的特征向量组合起来便求得该图像的特征向量。

4.2.2 SVM 模型建立

在样本空间中，划分超平面可通过如下线性方程来描述：

$$w^T x + b = 0 \quad (2-5)$$

其中 $w = (w_1; w_2; \dots; w_d)$ 为法向量，决定了超平面的方向； b 为位移项，决定了超平面与原点之间的距离。显然，划分超平面可被法向量 w 和位移 b 确定，将其记为 (w, b) 。样本空间中任意点 x 到超平面 (w, b) 的距离可写为

$$r = \frac{|w^T x + b|}{\|w\|} \quad (2-6)$$


假设超平面 (w,b) 能将训练样本正确分类，即对于 $(x_i, y_i) \in D$,若 $y_i = +1$ ，则有 $w^T x_i + b > 0$;若 $y_i = -1$ 则有 $w^T x_i + b < 0$,令

$$\begin{cases} w^T x_i + b \geq +1 \\ w^T x_i + b \leq -1 \end{cases} \quad (2-7)$$

如图所示，距离超平面最近的这几个样本点使式 2-7 的等号成立，他们被称为“支持向量”，两个异类支持向量到超平面的距离之和为

$$\gamma = \frac{2}{\|w\|} \quad (2-8)$$

他们被称为间隔



支持向量与间隔

欲找到最大间隔的划分超平面，也就是要找到满足式 2-7 中约束参数 w 和 b ，使得 γ 最大，即

$$\max_{w,b} \frac{2}{\|w\|} \quad (2-9)$$

$$\text{s. t. } y_i(w^T x_i + b) \geq 1$$

为了最大化间隔，仅需最大化 $\|w\|^{-1}$,这等价于最小化 $\|w\|^2$ 于是，式 2-9 可重写为

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (2-10)$$

$$\text{s. t. } y_i(w^T x_i + b) \geq 1$$

SVM 模型，它主要用于二分类问题，具有良好的可泛化性，本模块（人脸检测）的核心就是判断检测窗口是否有人脸，所以 SVM 可以较好的完成该工作。在人脸检测中，仅将图片的 HOG 特征以及标签（是否有人脸）输入到 SVM 模型中进行训练就可以分析该图中是否有人脸的支持向量机。

4.2.3 人脸 68 个特征点的标定

人脸特征点的标定可以看做是人脸对齐，人脸对齐的目的是在第一步人脸检测的基础上，自动找到人脸上的眼睛鼻子嘴和脸轮廓等标志性特征位置，刻画人脸形状。

Dlib 使用了 ERT 也就是 GDBT 算法来实现该操作。DLIB 使用了残差作为优化的方向。GDBT（Gradient Boosting Decision Tree）也就是梯度提升树，一个 GDBT 树可以看做是很多个回归树组成的森林。GDBT 由两个概念组成 GB, DT，首先对这两个概念进行介绍：

1) BT

在 GDBT 中的 BT 代表的是回归树而不是分类树，与分类树不同，回归树使用了方差来划分节点，并且在叶子节点中是使用所有该类别的数据的平均值作为预测值。

2) GB

GDBT 由多棵决策树组成，也就是说 GDBT 是由多棵回归树共同决定最终的结果，GDBT 的最终结果是由每棵树最终预测值相加得到的。

在介绍回归树是提到，所有的叶子节点是使用该类别的数据的平均值作为预测值，但在决策树中最终叶子节点存放的是该平均值与各个样本真实值的差值。

构造好第一个回归树后，使用第一棵树的残差进行第二个棵树的构造以此类推，知道结果足够的理想。这也可以看做是用后续的树的工作是去拟合前面的树的误差，后面的树更加的注重前面预测的误差。

在 Dlib 的实现中有所不同，后续树的真实值就是原图标签，而当前前面的残差而是一开始的初始值+残差后的结果，与训练误差类似也是注重于误差的训练。

人脸特征点标定的过程

- 需要训练一棵 GDBT 树，目的是输入一些随机的特征点位置坐标以及一个人脸照片，通过该树刻画出人脸的真实形状。
- 在每一个节点对于输入图像进行划分的时候，使用的是像素差，在这里可以将整个图片的像素点看做是该图片的特征。此时，任选两个像素，取得两个特征点

的像素值的差。并且，随机指定一个数值，像素差与之比较，小于在左子树，大于在右子树。

- 重复若干次该操作，将分完的样本的方差最小的一个特征点以及该数值保存起来作为该节点的划分依据。直到分裂到叶子节点。叶子节点中保存当前叶子节点储存的图片的预测形状（所有图片形状的平均）与真实形状的差值的平均作为残差，当所有的叶子节点都构造完毕后，第一棵树的构造结束。

- 第一棵树训练出的结果与当前形状相加对当前形状进行更新，在第二棵树就负责将进一步的去和真实值贴近，以此类推，直到最后一个树的结论是人脸真实的形状。

至此，人脸特征点标定工作完成。

4.2.4 将 68 维向量映射到欧式空间

本项目最终目的是找到未出勤的学生，所以需要将本次课学生的照片与数据库中学生的照片逐个进行比对，也就是需要进行人脸比对。人脸的比对主要是将人脸特征映射到高维空间并计算距离，所以需要将人脸特征点标定出的 68 个特征点组成的特征向量进行一定的映射，dlib 将其映射为 128 维向量。

网上资料可得，选取 128 维向量的原因，是由于 Google 的 FaceNet 项目测试 128 维向量对人脸的区分效果最好。

#dims	VAL
64	86.8%±1.7
128	87.9%±1.9
256	87.7%±1.9
512	85.6%±2.0

所以，再次需要找到一个映射函数，使 68 个特征映射到 128 维空间后，两个不同人脸在该空间的距离越远，反之越近。Dlib 使用了残差网络来训练这一个模型。

4.2.5 计算距离比对人脸

这一部分较为简单，仅需要计算每两个个人脸的 128 维向量之间的距离，与特定的值(本次设定的值为 0.6)进行比较，小于该值则为相同人脸，不同则为两个人。计算公式如下：

$$\sqrt{\sum_1^i (x_i^2 - y_i^2)^2} \quad (2-11)$$

实验结果

测试图如下：




- 1, 人脸识别
通过识别，人脸上面出现了对应的检测框



- 2, 特征点标定
每个人脸的面部被标记 68 个点，如下图所示：



- 3, 人脸比对结果
每组图 of 的右侧为从给定图片中识别出的人脸。

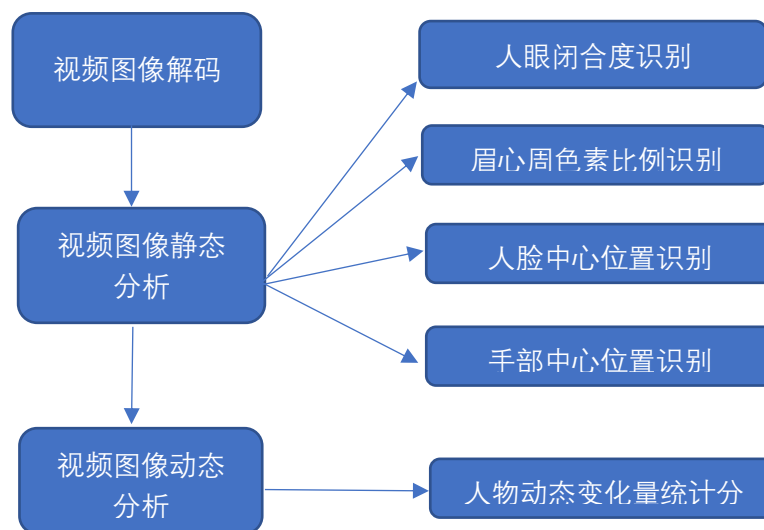


5 后期工作展望

本次由于时间紧张，功能一中没有时间实现通过微表情预测任务性格，因此在这里只叙述工作流程和原理。

传统的职业人格测试，需要人工填写人格测试题（本次人格预测采用传统人格预测），通过回答问题的结果判断一个人的人格特征，或者通过测评人员多次查看视频，主观判断一个人物的人格。视频识别技术日益成熟，能够智能识别人脸的特征值变化。把视频识别和人物人格特征分析相结合，那么人物人格特征分析可以不用人工参与，由计算机即可完成人物人格特征的分析，极大的提高了职业人格测试的便利性。

视频识别工作流程图：



视频识别示意图：



为了达到以上目的，采用的技术方案是：根据视频图像识别人格特征的方法，根据视频中区域的变化量来获得人物的细微表情变化和肢体动作变化，包括以下步骤：

基于人工智能技术改进的技术方案为：根据视频图像识别人格特征的方法，针对多个参考测定人进行人格评估测定得到多项人格特征因素评分值；采集参考测定人的人眼闭合频率、人脸移动轨迹、皱眉频率、手部动作轨迹，将上述数据导入人格预警模型内分析人物人格，得出人物人格特征报告，其中包括习惯性眨眼、人物是否有摇头的习惯、习惯性皱眉、录制视频时习惯性手部动作，并通过上述内容综合判断职业人员的人格情况。通过视频识别技术和人物人格特征分析技术相结合，通过采集人眼闭合度识别、眉心周色素量识别、人脸中心位置识别、手

部中心位置识别、人物动作的变化量来智能识别人物人格特征。

1)职业人员先进行视频沟通，结束后将该视频进行解码，将视频的内容解析成多张连续的图片；

2)针对解析后的每张图片中的人眼闭合度、人脸中心位置、眉心周色素量和手部中心位置四个区域进行静态分析；

3)将每张静态分析后的图片数据依次输入视频动态分析模块中，对每张图片的四个区域进行依次比对，进而获得四个区域的变化量，获得人眼闭合频率、人脸移动轨迹、皱眉频率、手部动作轨迹；

4)根据以上数据导入人格预警模型内分析人物人格，得出人物人格特征报告，其中包括习惯性眨眼、人物是否有摇头的习惯、习惯性皱眉、录制视频时习惯性手部动作，并通过上述内容综合判断职业人员的人格情况。

通过视频识别技术和人物人格特征分析技术相结合，通过采集人眼闭合度识别、眉心周色素量识别、人脸中心位置识别、手部中心位置识别、人物动作的变化量来智能识别人物人格特征。

所述人格预警模型的建立包括：选择多个参考测定人员进行人格评估测定得到作为参考测定人的人格特征因素真实基准评分的多项人格特征因素评分值；采集多个所述参考测定人员正常视频沟通的视频片段，对所述视频片段进行预处理并提取四个区域特征，并统计其特征值；将每一个参考测定人的多项人格特征因素评分值以及视频片段输入人格预警模型内，并在人格预警模型形成不同人格特征的基础数据。参考测定人员进行人格评估测定具体是指进行大五人格测试